

Симметричные семейства алгоритмов

$\mathbb{X} = (x_i)_{i=1}^L$ — генеральная выборка из L объектов;

$[\mathbb{X}]^\ell$ — множество всех разбиений полной выборки \mathbb{X} на (X^ℓ, X^k) .

Алгоритм — бинарный вектор $a \equiv (a(x_i))_{i=1}^L$ длины L ;

$\mathbb{A} = \{0, 1\}^L$ — множество всех алгоритмов длины L ;

Детерминированный метод обучения — отображение вида $\mu: 2^{\mathbb{A}} \times [\mathbb{X}]^\ell \rightarrow \mathbb{A}$;

Рандомизированный метод обучения — отображение вида $\mu: 2^{\mathbb{A}} \times [\mathbb{X}]^\ell \times \mathbb{A} \rightarrow [0, 1]$;

Рандомизированная минимизация эмпирического риска — отображение, заданное как

$$\mu(A, X, a) = \begin{cases} \frac{1}{|A(X)|}, & a \in A(X), \\ 0, & a \notin A(X); \end{cases} \quad (1)$$

где $A(X) = \underset{a \in A}{\operatorname{Argmin}} n(a, X)$;

Вероятность получить a в результате обучения: $P_\mu(a, A) = \frac{1}{C_L^\ell} \sum_{X \in [\mathbb{X}]^\ell} \mu(A, X, a)$;

Уклонение частот — $\delta(a, X^\ell) = \nu(a, X^k) - \nu(a, X^\ell)$, где $\nu(a, X) = \frac{1}{|X|} n(a, X)$;

Вклад a в вероятность переобучения: $Q_\mu(a, A) = \frac{1}{C_L^\ell} \sum_{X \in [\mathbb{X}]^\ell} \mu(A, X, a) [\delta(a, X) \geq \varepsilon]$

Вероятность переобучения: $Q_\mu(A) = \sum_{a \in A} Q_\mu(a, A)$, т.е. сумма вкладов алгоритмов.

Граф смежности множества алгоритмов — направленный граф $T(A) = (A, E)$, вершины которого соответствуют алгоритмам из A , а ребро $(a_1, a_2) \in E$ соединяет пары алгоритмов, чьи вектора ошибок отличаются только на одном объекте: $\rho(a_1, a_2) = 1$, причем число ошибок алгоритма a_2 на единицу больше, чем у a_1 .

Определение 1. Группой автоморфизма графа смежности $T(A) = (A, E)$ множества алгоритмов A называют подгруппу $\operatorname{Aut}(T(A))$ группы перестановок вершин графа, такую что каждый ее элемент $\pi \in \operatorname{Aut}(T(A))$ удовлетворяет двум условиям:

- Сохранение ребер графа и их ориентации:

$$(a_1, a_2) \in E \rightarrow (\pi(a_1), \pi(a_2)) \in E; \quad (2)$$

- Сохранение числа ошибок алгоритмов:

$$n(a, \mathbb{X}) = n(\pi(a), \mathbb{X}). \quad (3)$$

Определение 2. Группой симметрий множества алгоритмов $A \in 2^{\mathbb{A}}$ назовем подгруппу $S(A)$ группы перестановок объектов выборки, такую что для всякого $\pi \in S(A)$ выполнено $\pi(A) = A$.

Классы идентичных алгоритмов — орбиты действия группы симметрий $S(A)$ на множестве алгоритмов A . $\Omega(A)$ — совокупность всех орбит множества алгоритмов A . $a_\omega \in A$ — представитель орбиты $\omega \in \Omega(A)$.

Теорема 1. Идентичные алгоритмы дают равный вклад в вероятность переобучения:

$$Q_\mu(A) = \sum_{\omega \in \Omega(A)} |\omega| Q_\mu(A, a_\omega). \quad (4)$$

Задачи

Задача 1. Приведите нетривиальный пример рандомизированного метода обучения, отличный от рандомизированной минимизации эмпирического риска.

Задача 2. Приведите пример множества алгоритмов, в котором все алгоритмы имеют равную вероятность реализоваться в результате обучения методом минимизации эмпирического риска $P_\mu(a, A)$? Можете ли вы доказать свое утверждение? Останется ли справедливым ваше утверждение, если вместо рандомизированной минимизации эмпирического риска рассматривать произвольный рандомизированный метод обучения?

Задача 3. В каких пределах может меняться уклонение частот $\delta(a, X^\ell)$?

Задача 4. Докажите, что группа симметрии семейства алгоритмов равна пересечению групп симметрии слоев данного семейства.

Задача 5. Найдите группу симметрии множества, состоящего из одного алгоритма a с числом ошибок $t = n(a, X)$.

Задача 6. Пусть известны группы симметрии множества алгоритмов A_1 и A_2 . Найдите группу симметрии множества алгоритмов $A = \begin{pmatrix} A_1 & 0 \\ 0 & A_2 \end{pmatrix}$.

Задача 7. Найдите группу симметрии для следующего множества алгоритмов:

$$\begin{pmatrix} 1 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 & 1 \end{pmatrix}$$

Задача 8. Докажите теорему о равном вкладе идентичных алгоритмов в вероятность переобучения для случая, когда вместо группы симметрии вам известна только некоторая ее подгруппа $G \subset S(A)$.

Задача 9. Найдите группу симметрии шара алгоритмов $A_r(a_0) = \{a: \rho(a, a_0) \leq r\}$. Опишите классы идентичных алгоритмов.

Задача 10. Найти группу симметрии монотонной и унимодальной сетки (определения см. в статье П. Ботова, ММРО'09)

Задача 11. Покажите, что для множества алгоритмов со связным графом смежности в приведенном выше определении условие 3 является избыточным.

Задача 12. Доказать, что группа симметрии множества алгоритмов A изоморфно вкладывается в $\text{Aut}(T(A))$.

Задача 13. Докажите, что для любого множества алгоритмов $A \in 2^{\mathbb{A}}$ и любой перестановки $\pi \in S_L$ группы $S(A)$ и $S(\pi(A))$ изоморфны. Подсказка: докажите, что они сопряжены $S(\pi(A)) = \pi \circ S(A) \circ \pi^{-1}$ и проверьте, что сопряжение устанавливает изоморфизм групп.

Задача 14. (*) Согласно теореме Келли любая конечная группа вкладывается в группу перестановок S_L (при достаточно большом L). Верно ли, что любую конечную группу можно представить как группу симметрии некоторого множества алгоритмов?